Representação de Dados e XML

Bancos de Dados

Luiz Celso Gomes-Jr
gomesjr@dainf.ct.utfpr.edu.br

Representando Dados

- Antes da invenção do computador, a grande maioria dos dados eram representados em papel
- No papel, **texto, figuras, tabelas**, etc. são representados com tinta e cabe ao leitor identificar os diferentes elementos e entender o conteúdo
- No computador, precisamos saber de antemão com que **tipo de dados** estamos lidando para representá-los adequadamente

Processando Dados

- Quanto mais "organizados" (estruturados) os dados, mas simples é o processamento
- Exemplo de dados **estruturados**: listas, tabelas, matrizes
- Exemplo de dados **não-estruturados**: texto, imagens, sons
- Exemplo de dados **semiestruturados**: árvores, grafos

Processando Dados

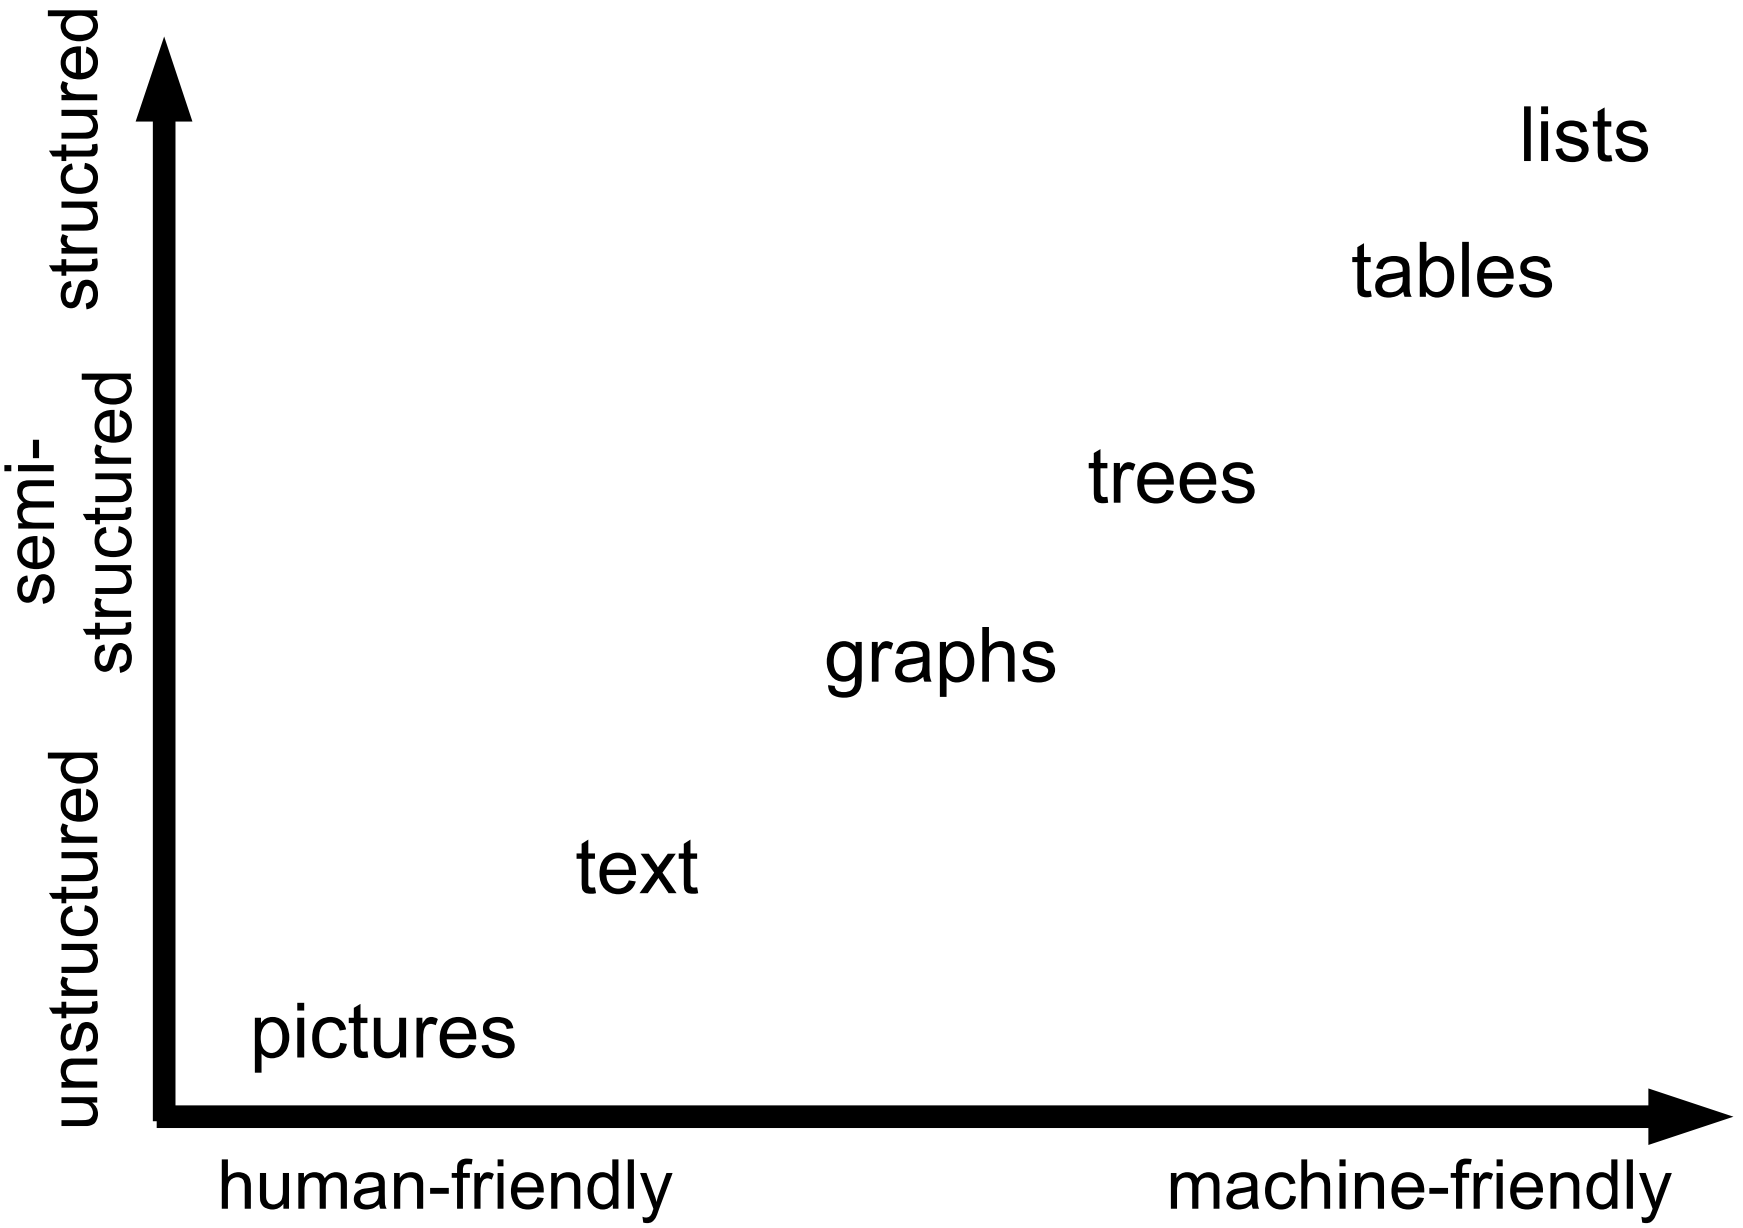

Principais modelos de dados

- Modelo Relacional (tabelas - foco do curso)
- Modelo hierárquico (árvores - foco desta aula)
- Modelo de grafos (veremos no fim do curso)

Importância dos modelos

- Permitem a separação entre representação dos dados e a implementação física das estruturas
- Exemplo de ED1: um programador pode implementar um programa que usa uma lista encadeada e no futuro mudar a implementação das bibliotecas para uma lista duplamente encadeada sem precisar alterar o programa principal

Importância dos modelos

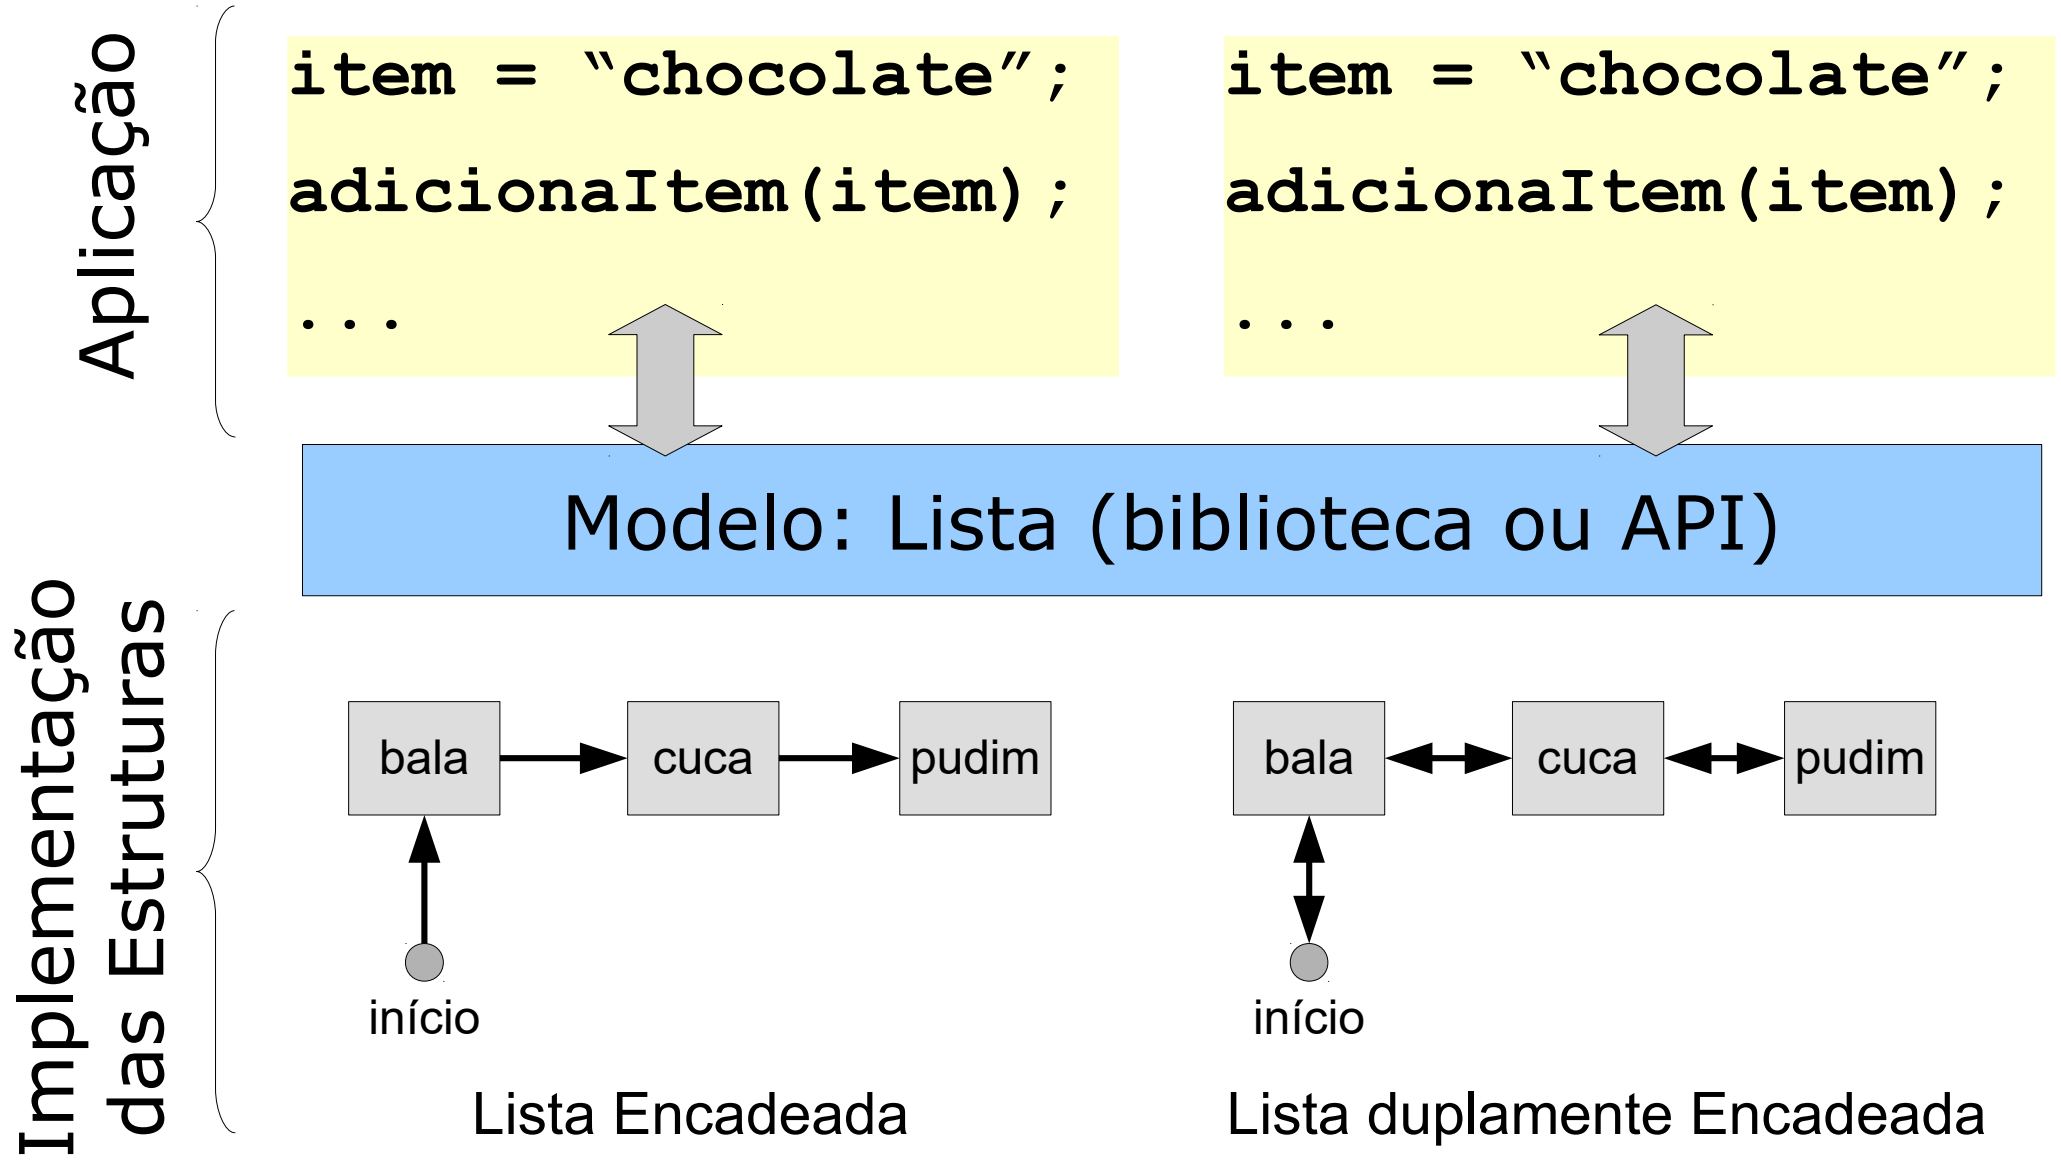

Importância dos modelos

- Em grandes empresas, os mecanismos de armazenamento mudam frequentemente para atender às demandas e isto não pode afetar as aplicações
- Exemplos: atualização de versão do SGBD, mudança de fornecedor de SGBD, upgrade de SGBD centralizado para SGBD distribuído

Modelo Hierárquico

- Usado para representar diversos tipos de dados
- Exemplos: Documentos, Categorias de Produtos, Modelos Orientados a Objeto, Disciplinas (tópicos, conteúdo, tarefas)
- Relativamente **flexível** e processamento relativamente **eficiente** (no meio do caminho entre tabelas e grafos)
- **XML** é o principal padrão para representação e compartilhamento de dados

XML – eXtensible Markup Language

XML

- Lançada em 1996 como uma versão simplificada da SGML (*Standard Generalized Markup Language*), para ser utilizada na *Web*.

Metalinguagem

- Tal como SGML, XML é uma metalinguagem.
- HTML ao contrário, foi escrita em SGML.

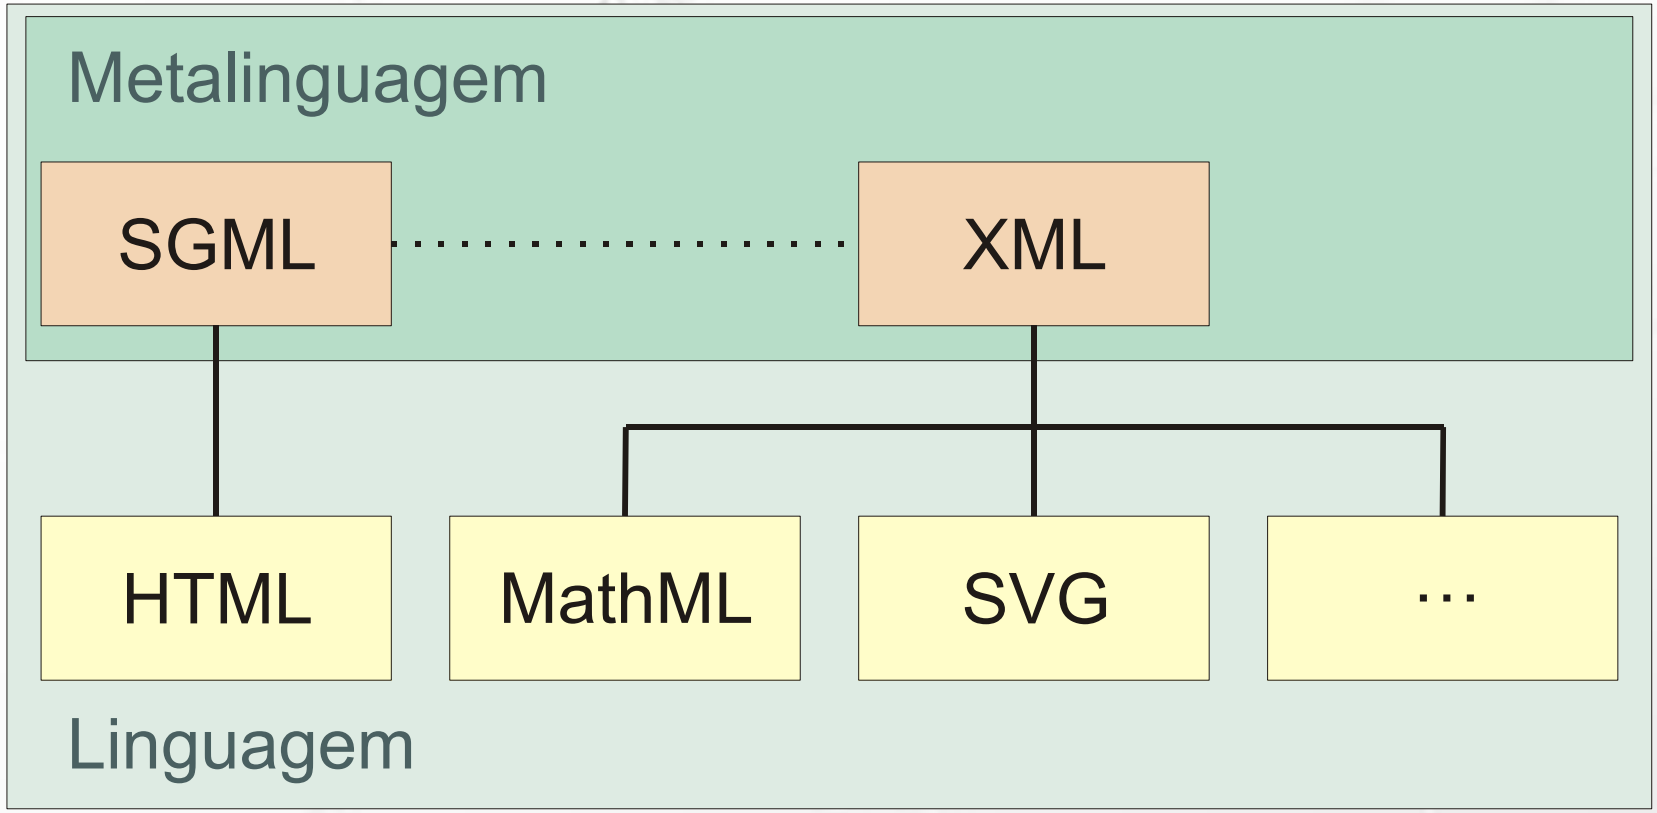

Linguagem de Marcação

- Utiliza marcadores para agregar informações adicionais a documentos.
- Tomemos como exemplo a seguinte frase:

Horácio escreveu o livro Vida dos Dinossauros.

- Desejamos agregar informações que identifiquem quem é o **autor** e qual a **ação** realizada.

Linguagem de Marcação

- Os marcadores se diferenciam do conteúdo pelos símbolos “<” e “>” (seguem o mesmo princípio de HTML):

<autor>Horácio**</autor> <ação>**escreveu o livro Vida dos Dinossauros**</ação>**

- Os marcadores delimitam unidades estruturais denominadas **elementos**.

Estrutura Hierárquica

- Marcações podem ser agrupadas hierarquicamente.
- A interpretação de cada marcador está subordinada a seu contexto.

```
<sentença>
  <autor>Horácio</autor>
  <ação>escreveu o
    <publicação>
      <tipo>livro</tipo>
      <título>Vida dos Dinossauros</título>
    </publicação>
  </ação>
</sentença>
```

Modelo de Dados XML

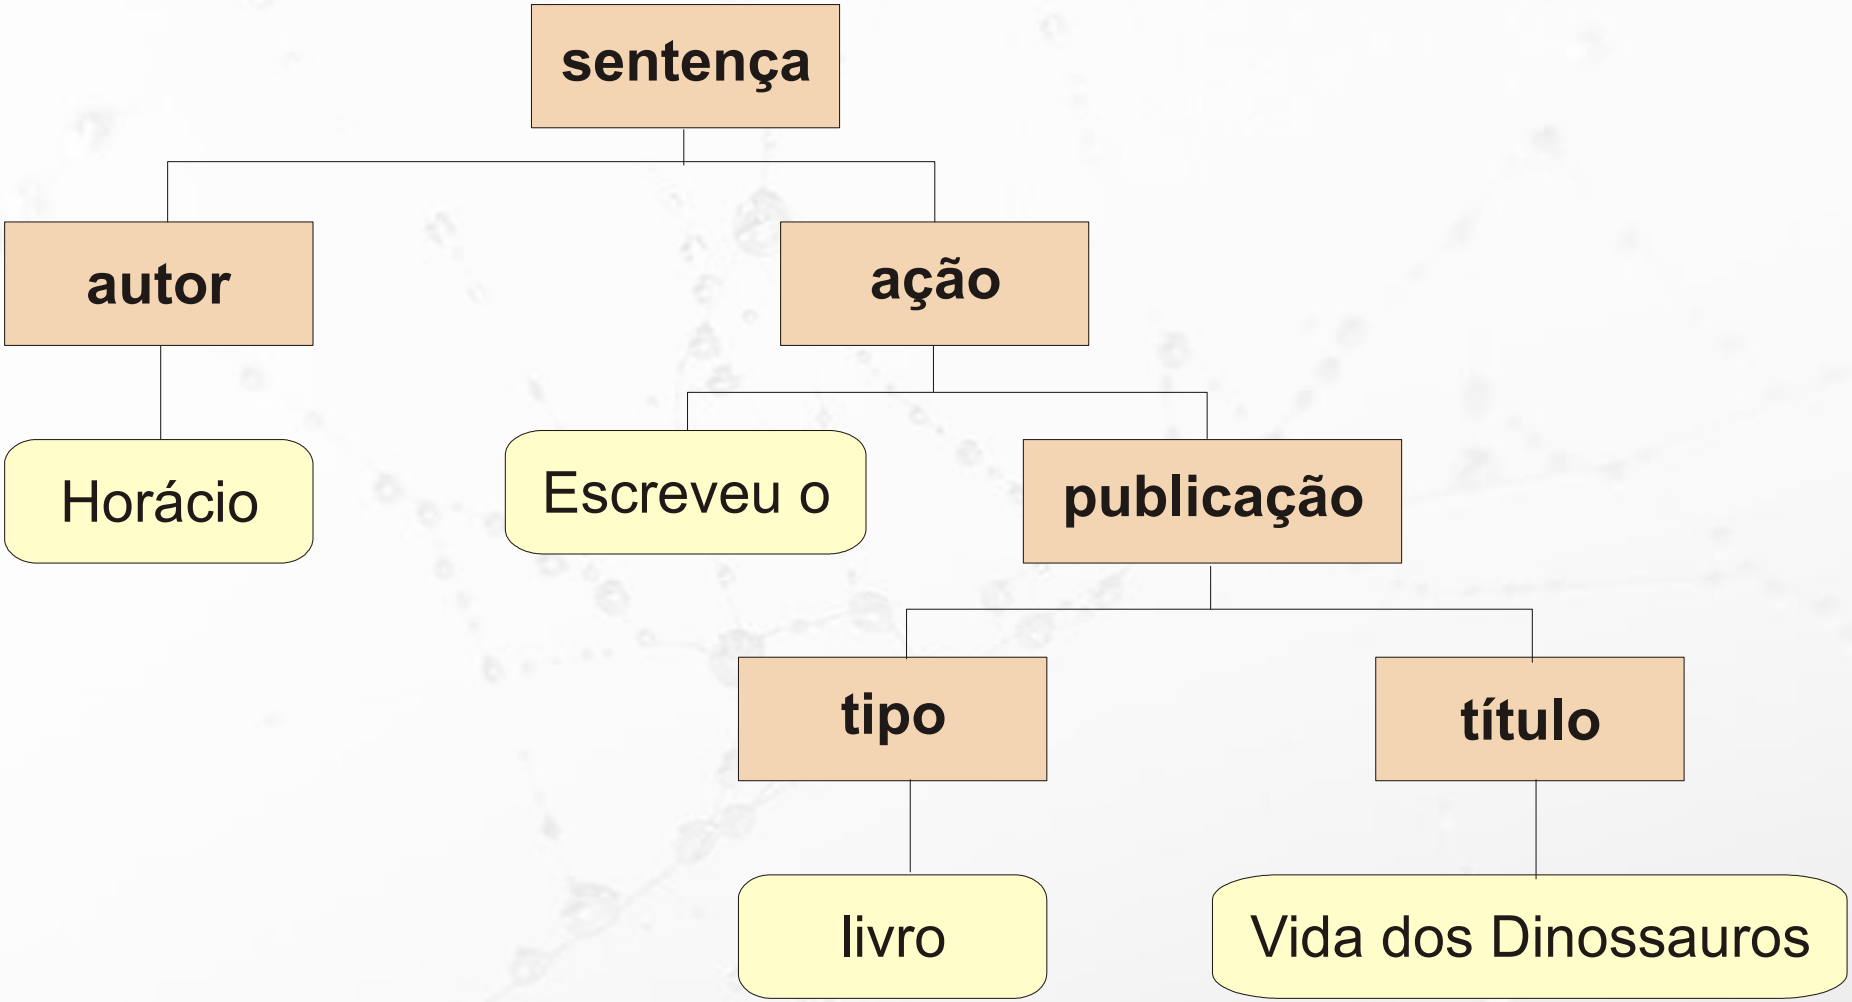

Elementos e Atributos

- Atributos:

```
<autor cpf=”487.526.548-74” nascimento=”12/5/1960”>
    Horácio
</autor>
```

- Elementos vazios:

```
<esgotado/>
```

Validação de Documentos

- Documento bem formado:
  - atende às regras de construção XML
- Documento válido:
  - bem formado
  - atende a um esquema
    - DTD
    - XML Schema

DTD

- O documento XML pode se basear em uma gramática definida através de uma DTD (*Document Type Definition*).

```
<!ELEMENT documento (topico+)>
<!ELEMENT topico (titulo, subtopico*)>
<!ELEMENT titulo (#PCDATA)>
<!ELEMENT subtopico (titulo, #PCDATA)>
```

XML Schema

- Padrão para definição de esquemas XML
- Mais poderoso

Tipos Simples

```
<xs:element name="business">
  <xs:simpleType>
    <xs:restriction base="xs:string">
      <xs:maxLength value="30"/>
    </xs:restriction>
  </xs:simpleType>
</xs:element>
```

(Wilde, 2006)

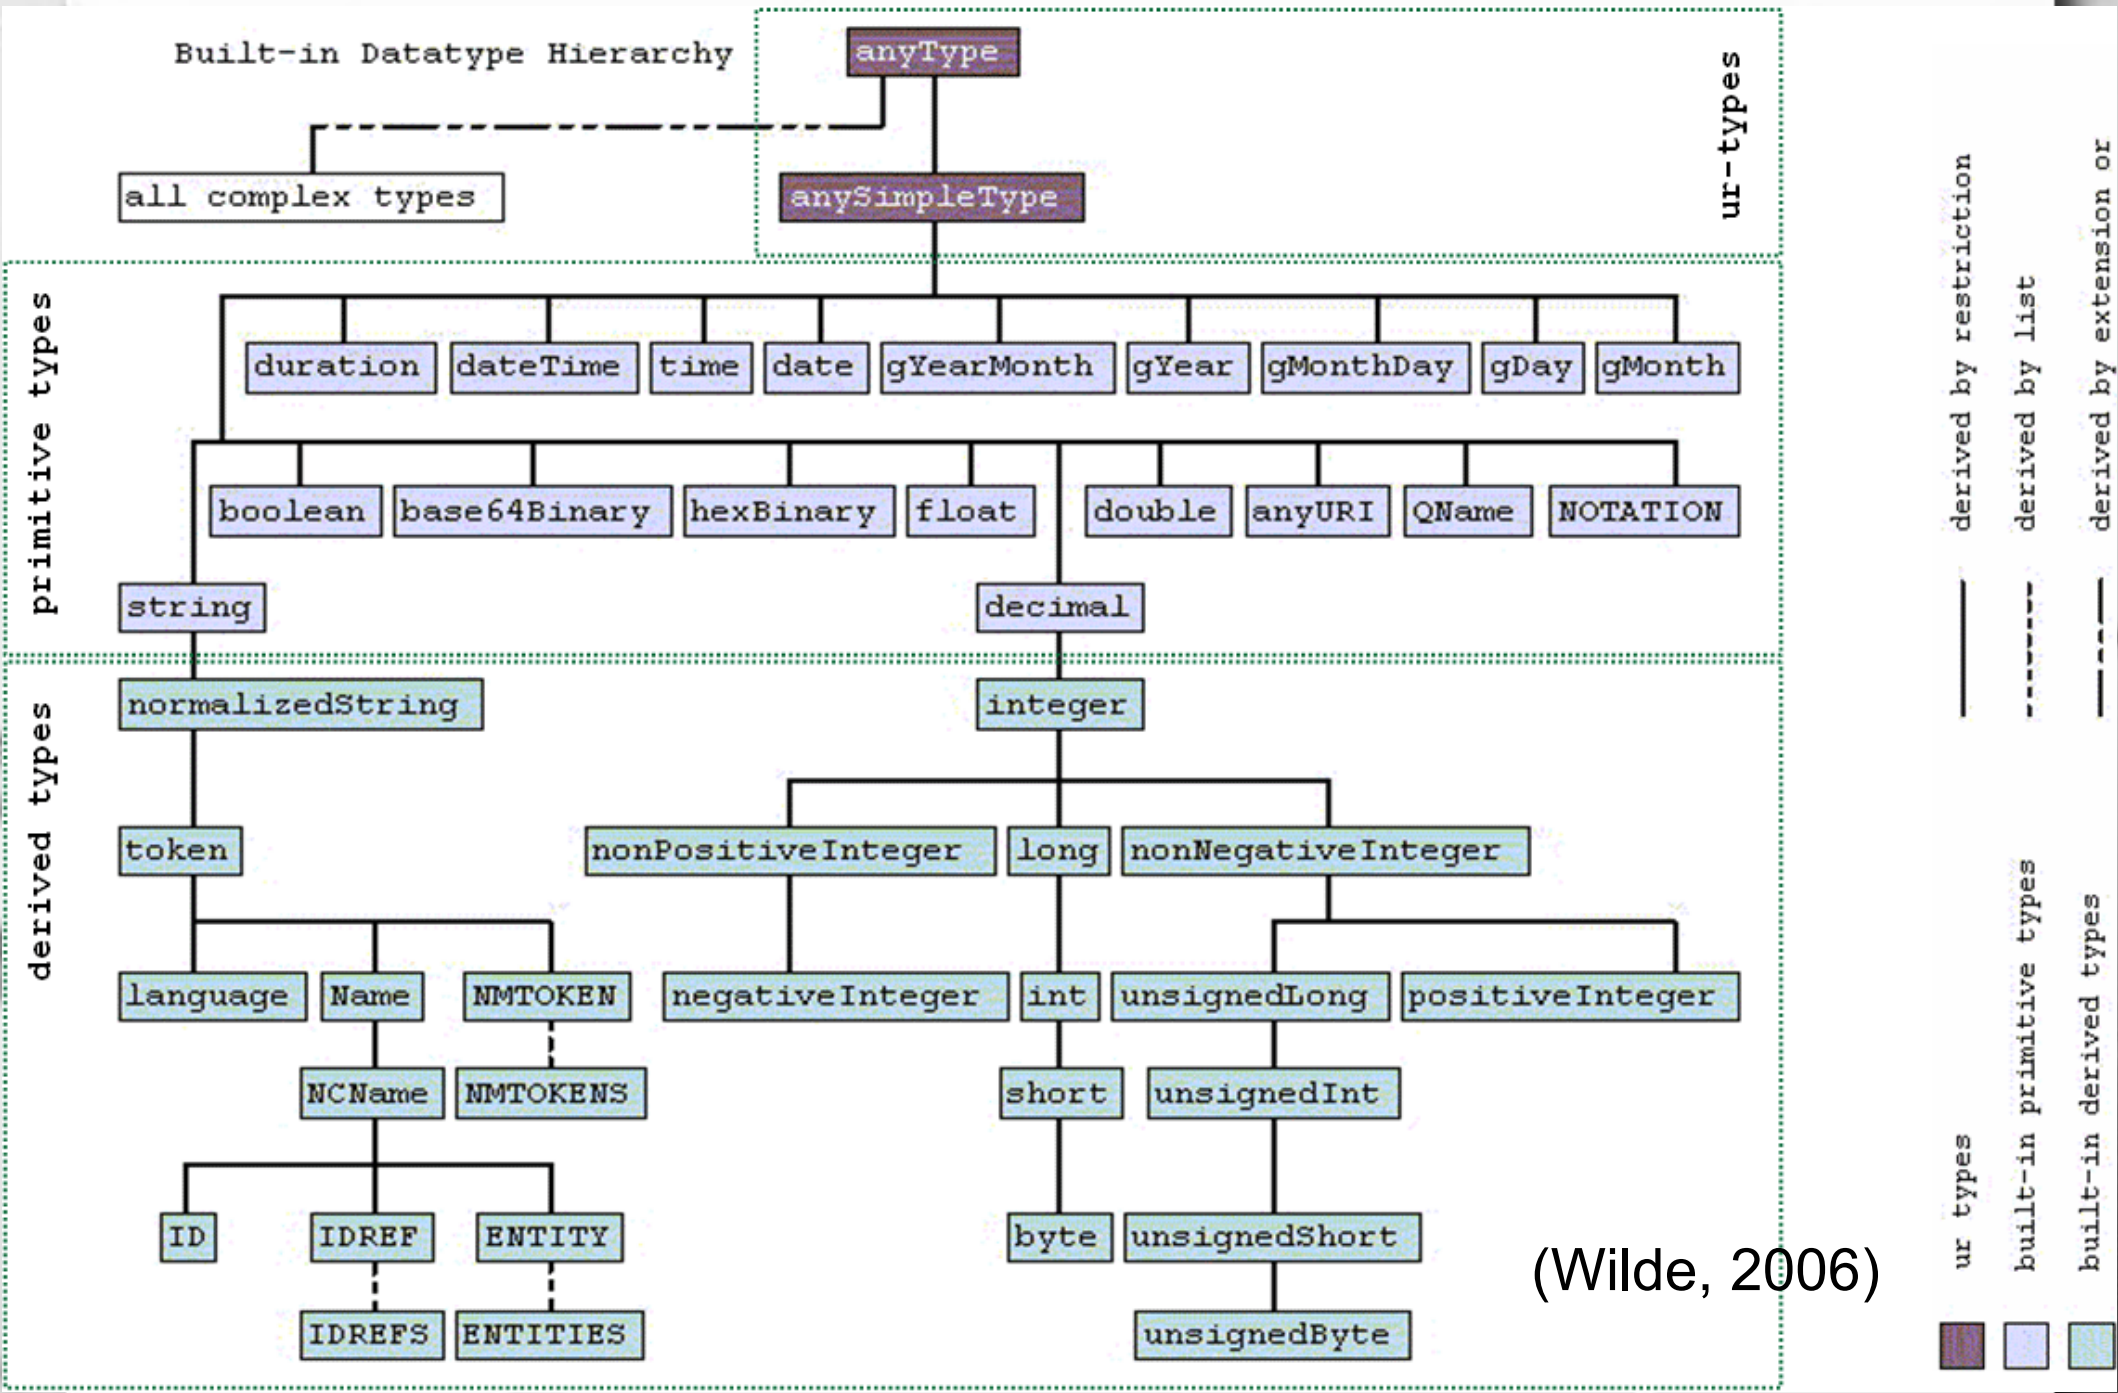
Built-in Datatype Hierarchy
anyType
all complex types
anySimpleType
ur-types
primitive types
duration
dateTime
time
date
gYearMonth
gYear
gMonthDay
gDay
gMonth
boolean
base64Binary
hexBinary
float
double
anyURI
QName
NOTATION
string
decimal
derived types
normalizedString
integer
token
nonPositiveInteger
long
nonNegativeInteger
language
Name
NMTOKEN
negativeInteger
int
unsignedLong
positiveInteger
NCName
NMTOKENS
short
unsignedInt
ID
IDREF
ENTITY
byte
unsignedShort
IDREFS
ENTITIES
unsignedByte
derived by restriction
derived by list
derived by extension or
ur types
built-in primitive types
built-in derived types

(Wilde, 2006)

Tipo Composto

```
<xs:schema>
  <xs:element name="billingAddress" type="addressType"/>
  <xs:element name="shippingAddress" type="addressType"/>
  <xs:complexType name="addressType">
    <xs:sequence>
      <xs:element name="name" type="xs:string"/>
      <xs:element name="street" type="xs:string"/>
      <xs:element name="city" type="xs:string"/>
      <xs:element name="state" type="xs:string" minOccurs="0"/>
      <xs:element name="zip" type="xs:decimal"/>
    </xs:sequence>
    <xs:attribute name="country" type="xs:NMTOKEN"/>
  </xs:complexType>
</xs:schema>
```

(Wilde, 2006)

Query

- **XPath**
  - Especifica expressões na forma de caminhos que atendem padrões para alcançar nós específicos (elementos ou atributos)
- **XQuery**
  - Queries para XML (usam XPath)

 URI

- A identificação de um recurso é feita através de um URI – Uniform Resource Identifier.
- URI = URL ou URN

URI

- URL (*Uniform Resource Locator*): identifica recursos por meio de sua localização física na Internet.

  Ex.: http://www.paleo.org

  ftp://ftp.unicamp.br

  mailto:horacio@paleo.org

- URN (*Uniform Resource Names*): identificador é relacionado indiretamente com sua localização física na rede (exige um resolver).

  Ex.: urn:ogc:def:uom:celsius

  urn:mpegra:mpeg21:dii:iswc:T-041.220.506-1

Parser XML

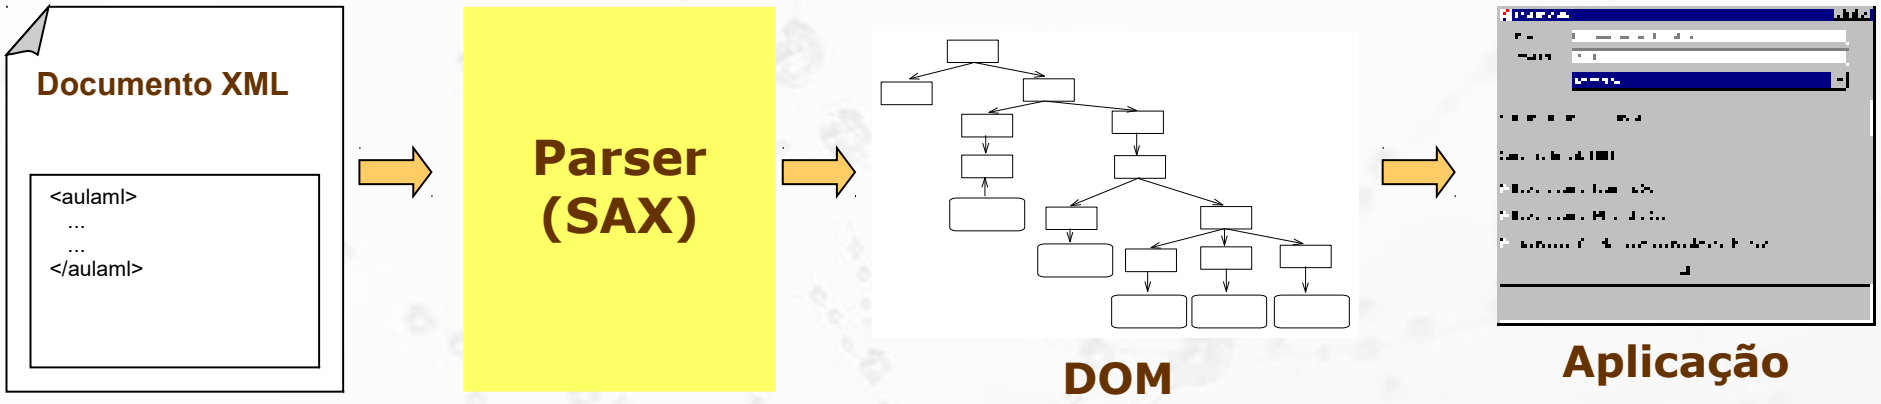

Introdução

Diversas tecnologias têm sido criadas para o processamento de documentos XML.

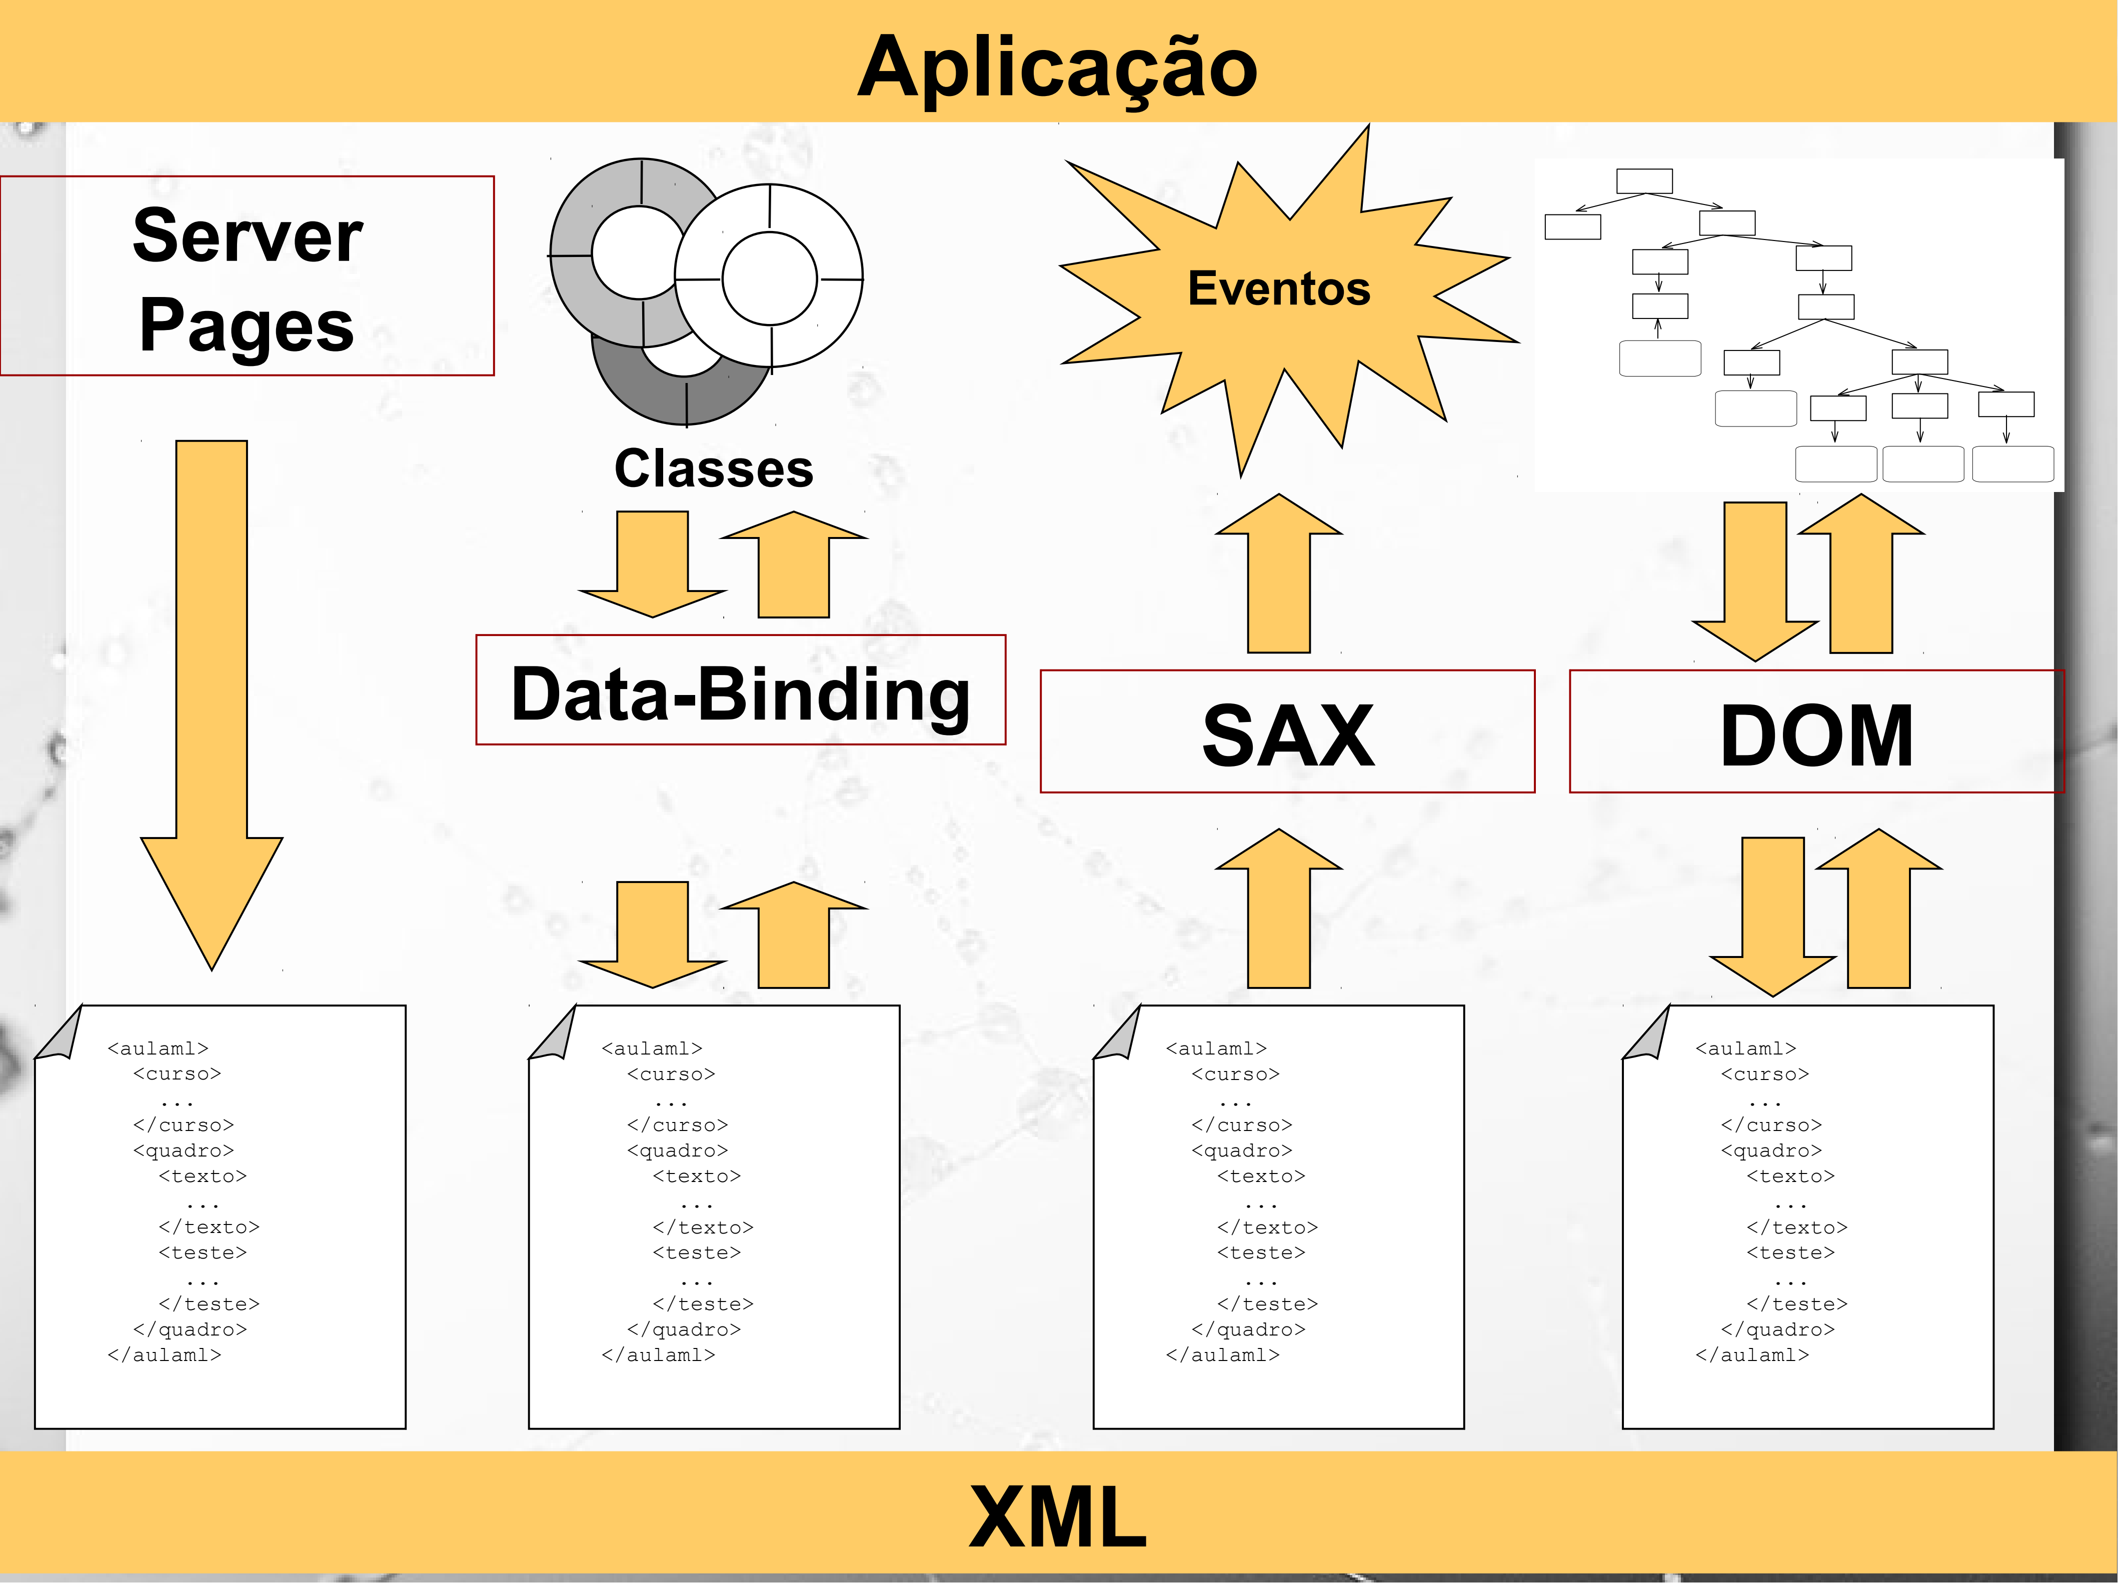

Aplicação
Server Pages
Classes
Data-Binding
Eventos
SAX
DOM
<aulaml> <curso> ... </curso> <quadro> <texto> ... </texto> <teste> ... </teste> </quadro> </aulaml>
<aulaml> <curso> ... </curso> <quadro> <texto> ... </texto> <teste> ... </teste> </quadro> </aulaml>
<aulaml> <curso> ... </curso> <quadro> <texto> ... </texto> <teste> ... </teste> </quadro> </aulaml>
<aulaml> <curso> ... </curso> <quadro> <texto> ... </texto> <teste> ... </teste> </quadro> </aulaml>
XML

Introdução

Dentre estas tecnologias duas se destacaram e se tornaram referência:

- SAX – Simple API for XML
- DOM – Document Object Model

SAX

- API baseada em eventos.
- Se tornou a mais estável API XML largamente utilizada [DOD01].
- Iniciou como uma solução para acesso a documentos XML por programas Java.
- Hoje tem sido portada para outras linguagens de programação, tal como: C++, Pascal, Perl, Phyton, etc.

Eventos de conteúdo

```
public class SAXBasico extends
             org.xml.sax.helpers.DefaultHandler
{

  public void startDocument() ...

  public void startElement(...) ...

  public void characters (...) ...

  public void endElement(...) ...

  public void endDocument() ...

}
```

Eventos de conteúdo

Método	Acionado quando o *parser* encontra
`startDocument`	início do documento
`startElement`	início de um elemento
`characters`	conteúdo texto
`endElement`	final de um elemento
`endDocument`	final do documento

DOM

- DOM define uma API para documentos XML e HTML.
- Ele acrescenta ao padrão destas linguagens toda a funcionalidade e flexibilidade que um programa precisa para acessar e manipular documentos.
- Definido em IDL, ECMAScript e Java.

Document Object Model

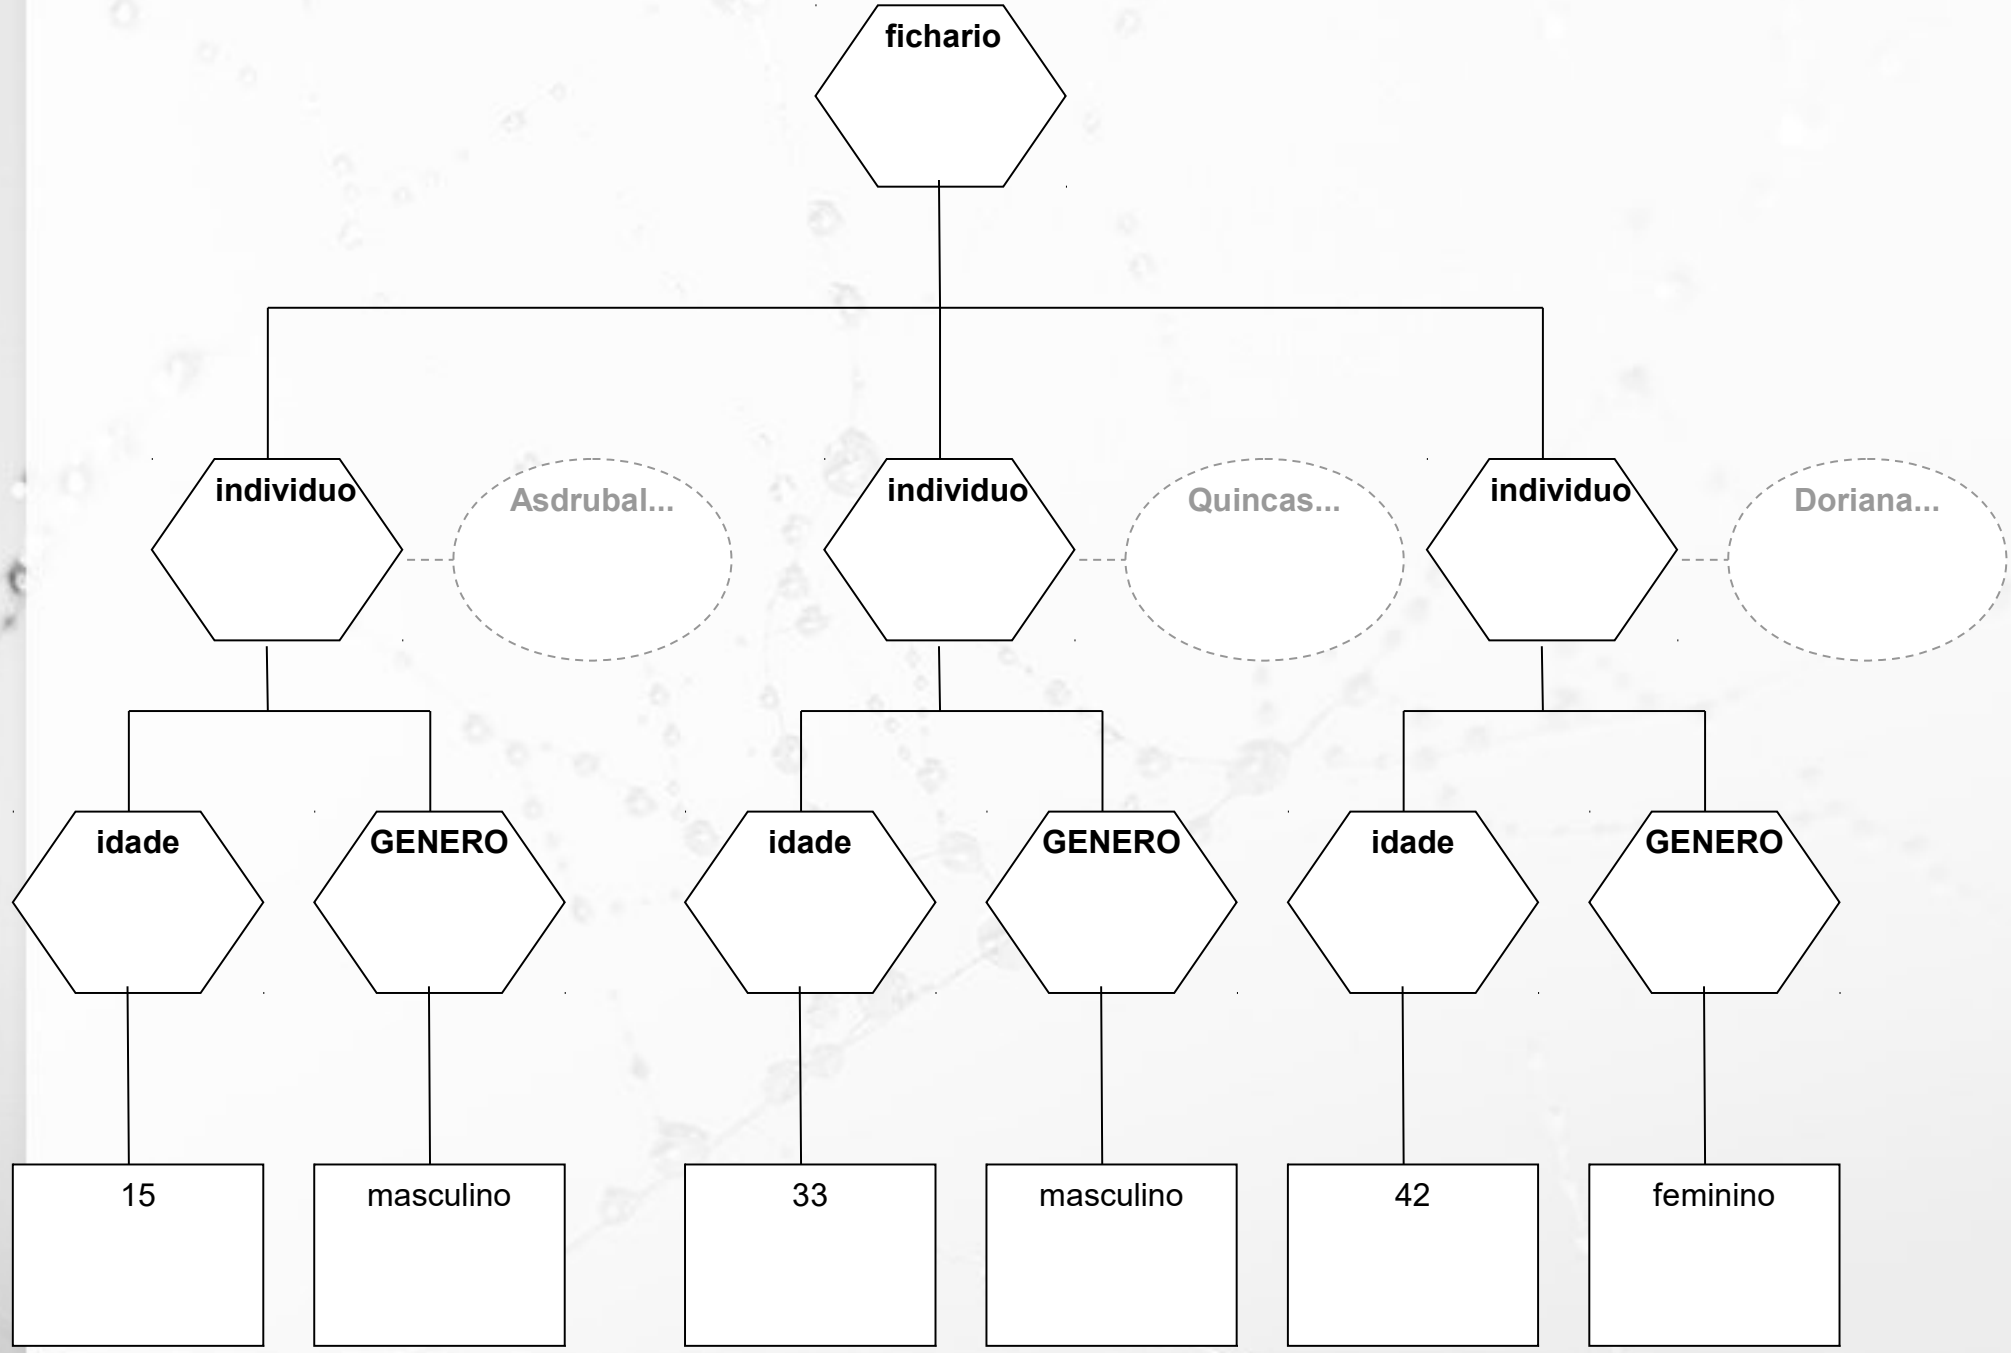

DOM - Estudo de Caso

```
<FICHARIO>
  <individuo nome="Asdrubal da Silva">
    <idade>15</idade>
    <genero>masculino</genero>
  </individuo>
  <individuo nome="Quincas Borba">
    <idade>33</idade>
    <genero>masculino</genero>
  </individuo>
  <individuo nome="Doriana Margarina">
    <idade>42</idade>
    <genero>feminino</genero>
  </individuo>
</FICHARIO>
```

Processo

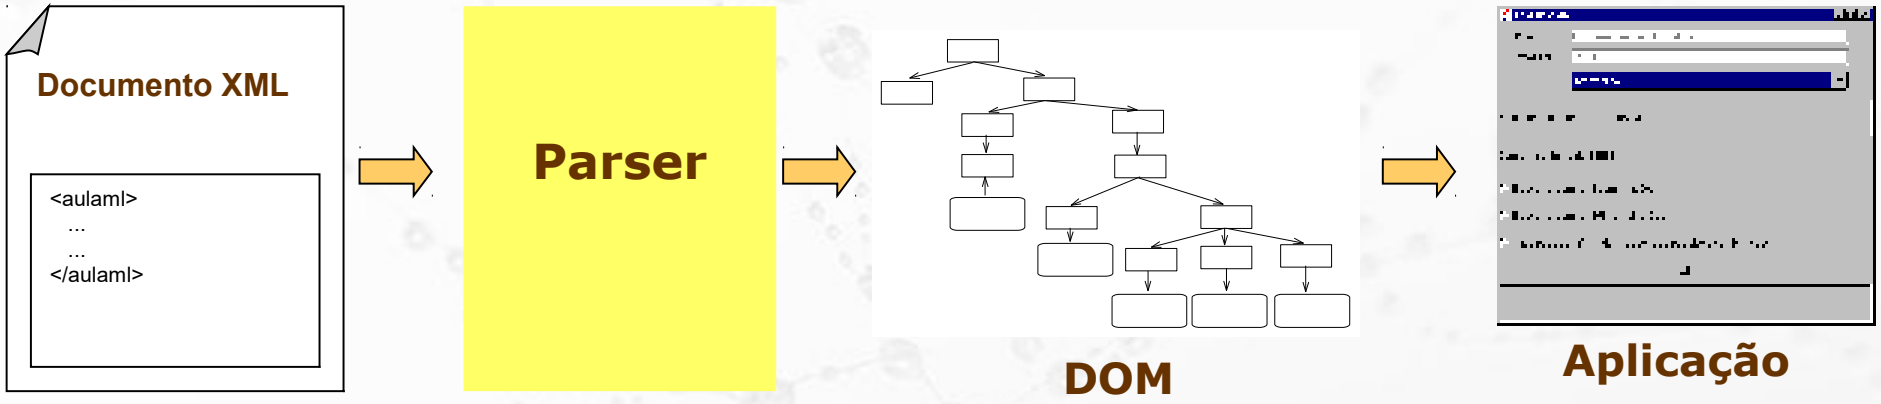

Interfaces

- **Node** – esta interface representa genericamente qualquer nó da árvore.
- **Element** – acrescenta propriedades e métodos específicos de um nó do tipo elemento.
- **Document** – interface do nó raiz da árvore que representa o documento completo.
- **NodeList** – representa uma lista de nós. Pode representar, por exemplo, a lista de filhos de um nó.

Navegar pelo Documento

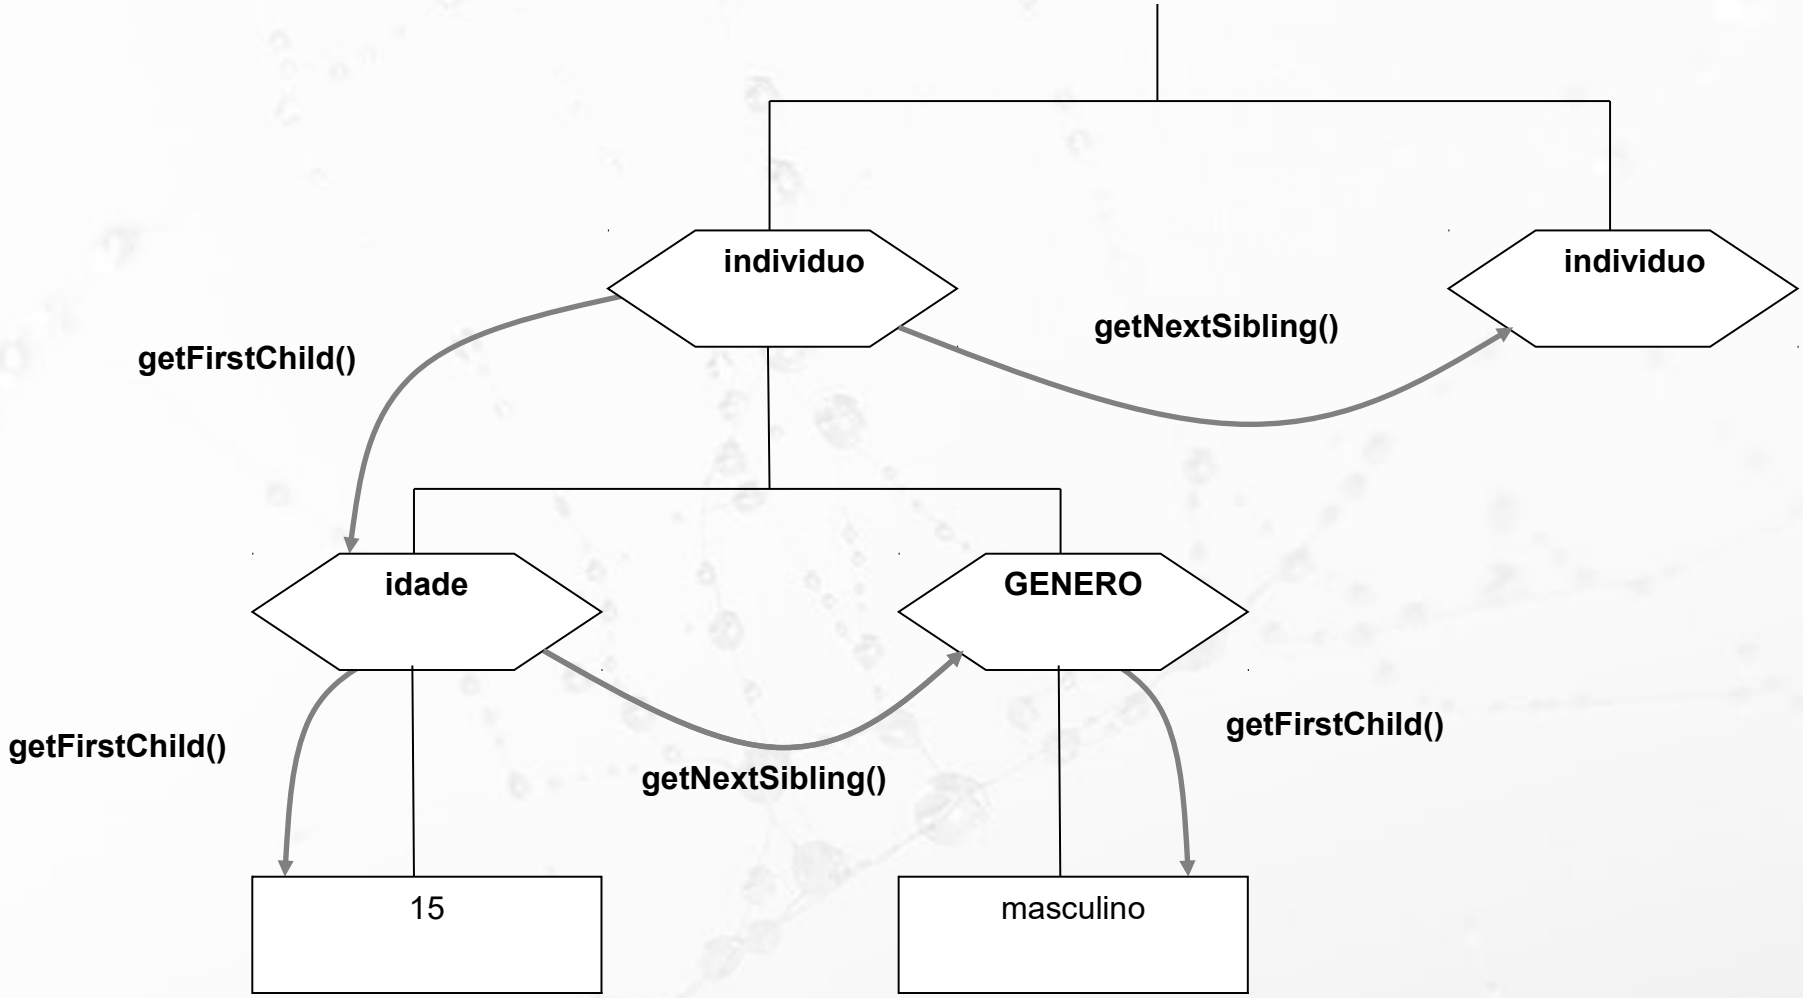

JSON

- Modelo de representação de dados semiestruturados
- Baseado em JavaScript com foco em aplicações Web
- Mais simples e mais leve que XML (mas também mais limitado)
- Não define linguagens (em definição)
- XML Nutella :)

JSON x XML

```
{"employees":[
    { "firstName":"John", "lastName":"Doe" },
    { "firstName":"Anna", "lastName":"Smith" },
    { "firstName":"Peter", "lastName":"Jones" }
]}
```

```
<employees>
    <employee>
        <firstName>John</firstName>
<lastName>Doe</lastName>
    </employee>
    <employee>
        <firstName>Anna</firstName>
<lastName>Smith</lastName>
    </employee>
    <employee>
```

Exercícios

- Dê exemplos de dados para cada tipo de modelo (relacional, hierárquico, grafos)
- Quais as vantagens de se usar um modelo padronizado como o XML?

Referências e Agradecimentos

- Diversos slides baseados no curso de BD do Prof. André Santanchè (UNICAMP)
  - Site: http://www.ic.unicamp.br/~santanche
  - Canal Youtube: https://www.youtube.com/santanche